# NER: Abordagens tradicionais e modernas

Ana Gabriela Maia, Bertrand Lira, Guilherme Pujoni, Lucas Marques Bezerra

CENTRO DE INFORMÁTICA
UNIVERSIDADE FEDERAL DA PARAÍBA

João Pessoa, 2026

Ana Gabriela Maia, Bertrand Lira, Guilherme Pujoni, Lucas Marques Bezerra

# NER: Abordagens tradicionais e modernas

Projeto da disciplina de Processamento de Linguagem Natural

Professor: Yuri Malheiros

Abril de 2026

# Sumário

**1 INTRODUÇÃO** **5**

1.1 Definição do Problema . . . . . 5

**2 OBJETIVOS** **6**

**3 DADOS UTILIZADOS E PRÉ-PROCESSAENTO DOS DADOS** **7**

**4 METODOLOGIA** **8**

4.1 Técnica utilizada . . . . . 8

4.2 Experimento para avaliar a técnica utilizada . . . . . 9

**5 RESULTADOS** **10**

5.1 REGEX . . . . . 10

5.2 N-GRAMAS . . . . . 11

5.3 BERT . . . . . 13

5.4 CONCLUSÃO . . . . . 14

**6 TRABALHOS FUTUROS** **15**

# 1 INTRODUÇÃO

O Reconhecimento de Entidades Nomeadas é uma aplicação do processamento de linguagem natural que objetiva a identificação de unidades informativas em textos brutos. O foco dessa técnica é a extração de características das respectivas entidades de forma a formalizá-las em dados estruturados para serem processadas eficientemente por sistemas computacionais, visto que a extração de informações de grandes volumes de texto mostra-se temporal e financeiramente inviável, especialmente em cenários de big data.

## 1.1 Definição do Problema

A eficácia de um sistema NER é dependente da escolha da técnica de processamento a ser aplicada, variando conforme limitações de custos computacionais e as demandas de precisão do contexto. Nesse cenário, a problemática central orbita na limitação de modelos com diferentes bases técnicas para o reconhecimento de entidades em um texto fentre ao nível de criticidade dos dados analisados e gerado. Subsiste, portanto, a necessidade de investigação das limitações de abordagens baseadas em regras rígidas e estatísticas de forma que o emprego de técnicas com foco em Aprendizagem de Máquina sejam suficientemente complexos e justifiquem o incremento no custo computacional, superando a rigidez dos modelos tradicionais.

# 2 OBJETIVOS

Diante do problema apresentado, o presente trabalho tem como objetivo comparar modelos de Processamento de Linguagem Natural com diferentes níveis de complexidade para o problema de NER (Reconhecimento de Entidades Nomeadas) sob uma base de dados (colhida da Wikipédia).

Além da comparação entre abordagens, o trabalho busca analisar o impacto da complexidade dos modelos na qualidade das predições, considerando desde métodos mais simples, como abordagens baseadas em regras (Regex) e modelos estatísticos baseados em n-gramas, até modelos mais sofisticados baseados em aprendizado profundo, como arquiteturas do tipo BERT.

Diante disso, pretende-se avaliar qualitativamente e quantitativamente o desempenho dos modelos, observando aspectos como capacidade de generalização, precisão na identificação de diferentes tipos de entidades (como pessoa, organização e localização) e robustez diante de textos de tamanhos variados.

Espera-se que os resultados obtidos contribuam para uma melhor compreensão das diferentes estratégias aplicáveis ao problema de NER, auxiliando na escolha de modelos mais adequados para cenários práticos que envolvam a extração de informação a partir de textos não estruturados.

# 3 DADOS UTILIZADOS E PRÉ-PROCESSAENTO DOS DADOS

A base de dados utilizada neste trabalho foi o dataset omarkamali/wikipedia-monthly, disponibilizado na plataforma Hugging Face, que consiste em dumps periódicos da Wikipédia em diferentes idiomas. Considerando o elevado volume de dados, com aproximadamente 1,18 milhão de artigos em português, tornou-se inviável utilizar o conjunto completo para os experimentos deste trabalho. Dessa forma, foi realizada uma amostragem, selecionando-se um subconjunto de 10.000 artigos, garantindo viabilidade computacional e agilidade nos testes, ao mesmo tempo em que se mantém uma base representativa. O dataset é estruturado em 4 colunas:

- **id**: identificador único de cada artigo;
- **title**: título do artigo da Wikipédia;
- **text**: conteúdo textual completo do artigo;
- **url**: link correspondente ao artigo original na Wikipédia.

Devido a ausência de um *Ground-Truth* na base de dados inicial, foi necessário utilizar o modelo de Reconhecimento de Entidades Nomeáveis da biblioteca SpaCy. O modelo foi aplicado sobre os textos da base de dados da Wikipédia com o objetivo de servir como referência inicial para treinar os modelos utilizados nesse trabalho.

Utilizando como entrada a base de dados da Wikipédia, o Spacy realizou a tokenização da coluna 'text' da entrada, que representa o texto dos artigos coletados. A tokenização do Spacy para NER é feita de forma diferente: letras maiúsculas e minúsculas devem ser mantidas, para capturar nomes próprios (representando uma possível entidade), pontuações foram excluídas e stopwords foram mantidas para a identificação desses tokens como O.

Após a tokenização, o Spacy retornou, além da coluna de tokens, a coluna de *labels* de cada token, ou seja, para cada token de um artigo, o SpaCy categorizou como O, B-PER, I-PER, B-LOC, I-LOC, B-ORG ou I-ORG.

Essa abordagem permitiu, inicialmente, contornar o problema da ausência de um conjunto de dados previamente rotulado, viabilizando a realização dos experimentos comparativos entre os modelos utilizados, sem a necessidade de uma revisão manual, que seria inviável devido ao alto custo de tempo e esforço.

Entretanto, é importante destacar que o gabarito gerado pelo SpaCy ainda está sujeito a erros e ruídos e limitações do próprio modelo, podendo impactar diretamente da avaliação dos modelos utilizados.

# 4 METODOLOGIA

A metodologia foca na implementação e avaliação de diferentes modelos para a tarefa de NER, utilizando o conjunto de dados previamente processado e rotulado conforme detalhado na seção anterior.

## 4.1 Técnica utilizada

Foram implementadas três abordagens principais para a tarefa de Reconhecimento de Entidades Nomeadas (NER), com um aumento de complexidade de modelos. Os experimentos foram realizados sobre os dados previamente processados e rotulados no formato BIO, permitindo comparar cada modelo e sua estrutura de captura de entidades.

Antes do treinamento dos modelos estatísticos, também foram utilizadas técnicas de representação vetorial e *feature engineering*, como *Bag-of-Words* e TF-IDF. Essas técnicas serviram para transformar os tokens e seus contextos em vetores numéricos, sendo usadas como base para a construção das *features* do modelo com n-gramas.

- **Baseline com Expressões Regulares (Regex):** A primeira abordagem foi baseada em regras manuais e padrões fixos de texto. Foram utilizadas heurísticas simples para tentar identificar entidades, como palavras iniciadas por letra maiúscula, listas de localidades e padrões comuns em nomes de organizações. Essa abordagem foi usada como linha de base por ser simples, interpretável e de baixo custo, embora tenha pouca capacidade de generalização.

- **N-gramas e Regressão Logística:** A segunda abordagem utilizou um modelo estatístico com contexto local. Nessa etapa, técnicas como *Bag-of-Words* e TF-IDF foram empregadas na construção de representações vetoriais, considerando principalmente bigramas e trigramas. Essas *features* foram então usadas em um classificador de Regressão Logística, responsável por prever o rótulo de cada token. Essa estratégia consegue capturar melhor o contexto do que no caso das regras fixas, mas ainda tem limitações para dependências mais longas no texto.

- **Fine-tuning do BERTimbau:** A terceira abordagem utilizou o modelo pré-treinado *neuralmind/bert-base-portuguese-cased*, adaptado para classificação de tokens. O modelo gera representações contextuais bidirecionais, permitindo que cada palavra seja analisada com base no restante da sentença. Na implementação inicial, a entrada era limitada a 128 tokens, o que fazia com que textos maiores fossem truncados. Por isso, foi necessário ajustar a lógica de processamento para percorrer o texto completo em vez de considerar apenas o primeiro trecho. Durante o treinamento, também foi feito o alinhamento dos rótulos com os fragmentos gerados

pelo tokenizador, ignorando subwords intermediárias na função de perda. Entre os hiperparâmetros mais relevantes, destacam-se 3 épocas de treinamento, *learning rate* de $2 \times 10^{-5}$, *batch size* 16 e *weight decay* de 0,01.

### 4.2 Experimento para avaliar a técnica utilizada

O experimento seguiu uma divisão de 80% dos dados para treinamento e 20% para teste para garantir a reprodutibilidade dos resultados. No ajuste do modelo BERT, aplicou-se o alinhamento de rótulos para ignorar fragmentos de sub-palavras (*subwords*) gerados pelo tokenizador.

O treinamento do modelo *Transformer* foi executado em uma GPU NVIDIA T4 (via Google Colab) com os seguintes hiperparâmetros:

- **Tamanho do lote (Batch size):** 16;
- **Comprimento de sequência:** 128 tokens;
- **Taxa de aprendizado (Learning rate):** 2e-5;
- **Épocas:** 3.

A avaliação consistiu no confronto direto entre as predições de cada técnica e o gabarito original presente no arquivo `.parquet`. Isso permitiu mensurar a acurácia global e o desempenho específico por categoria de entidade.

# 5 RESULTADOS

Nesta seção, será feita a comparação entre os resultados dos modelos descritos, sendo eles o Regex, N-gramas e o BERTimbau após o *fine tuning*.

## 5.1 REGEX

O modelo Regex apresentou uma média de F1-Score de 0.01, o que indica a ineficiência do modelo enquanto agente sobre o corpus apresentado. O conjunto de regras do Regex é insuficiente para apresentar um desempenho que se difere de um modelo aleatorizado, sendo, na prática, inviável para aplicação em grande parte dos contextos em que o NER se faz útil.

A matriz de confusão normalizada do modelo baseado em expressões regulares (Figura 1) evidencia uma forte tendência do modelo em classificar entidades como pertencentes à classe nula (0) e à classe PER (pessoas). Esse comportamento pode ser explicado pela natureza simplificada e generalista das regras utilizadas, que favorecem a identificação de padrões associados a nomes próprios. Em contrapartida, observa-se um desempenho significativamente inferior na identificação da classe ORG (organizações), o que sugere uma cobertura limitada das regras e da lista estática de termos utilizada para representar essa classe. Esse resultado indica que abordagens baseadas em regras apresentam dificuldades em capturar a diversidade e complexidade das expressões linguísticas presentes nos textos da Wikipédia.

**Tabela 1: Resultados do modelo Baseline Regex**

| Classe | Precision | Recall | F1-score |
|---|---|---|---|
| **LOC** | 0.06 | 0.01 | 0.01 |
| **ORG** | 0.01 | 0.00 | 0.00 |
| **PER** | 0.01 | 0.06 | 0.02 |
| **micro avg** | 0.02 | 0.03 | 0.02 |
| **macro avg** | 0.03 | 0.02 | 0.01 |
| **weighted avg** | 0.04 | 0.03 | 0.02 |

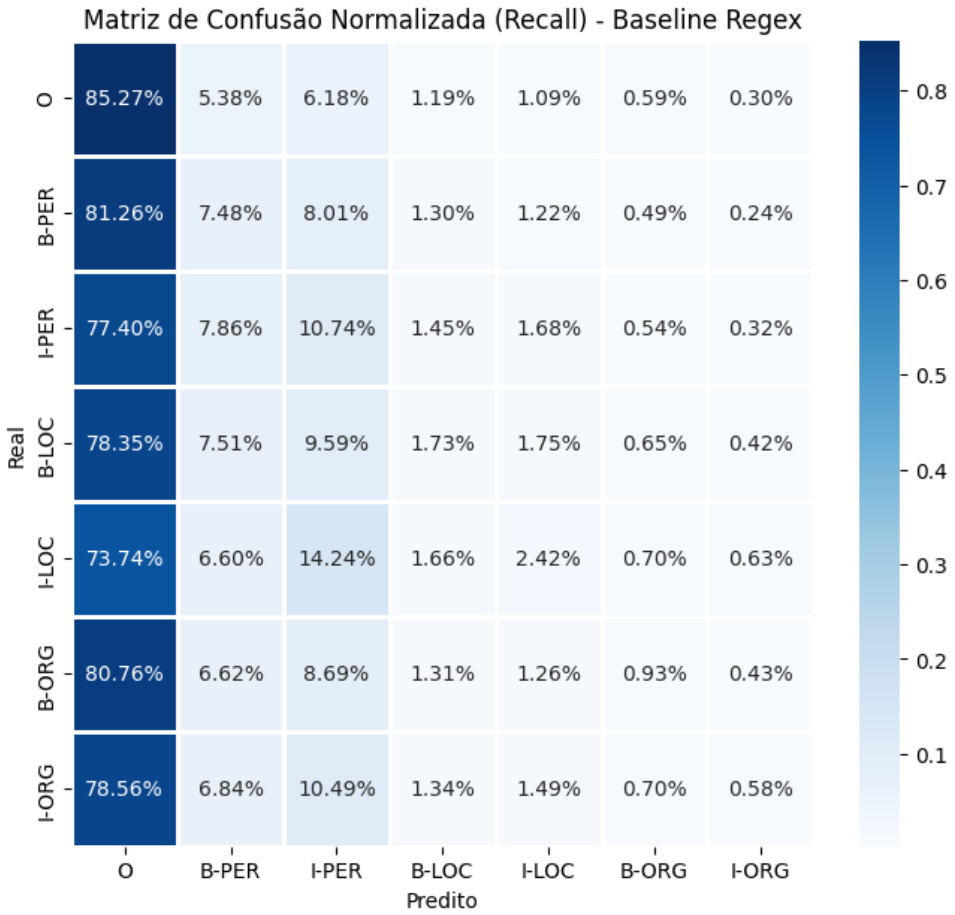


**Figura 1: Matriz de confusão para o Regex**

## 5.2 N-GRAMAS

O modelo baseado em n-gramas com Regressão Logística apresentou uma média de F1-Score de 0.11, indicando uma melhora em relação ao baseline baseado em expressões regulares, porém ainda insuficiente para um desempenho satisfatório na tarefa de Reconhecimento de Entidades Nomeadas. Apesar de capturar padrões locais no texto, o modelo demonstra limitações significativas na generalização, especialmente em classes com maior variabilidade contextual, tornando sua aplicação restrita em cenários mais complexos.

A matriz de confusão normalizada do modelo baseado em n-gramas (Figura 2) evidencia uma forte tendência do modelo em classificar entidades como pertencentes à classe nula (O). Esse comportamento é observado de forma consistente em todas as classes, com destaque para B-PER (89,81%), I-PER (74,66%), B-LOC (77,48%) e B-ORG (79,41%), que são majoritariamente classificadas como não entidade. Tal padrão indica uma baixa capacidade do modelo em identificar entidades nomeadas, impactando diretamente a métrica de recall.

Apesar disso, observa-se um desempenho relativamente superior em algumas clas-

ses específicas, como I-LOC, que apresenta 45,42% de classificações corretas, e I-PER, com 22,13%, sugerindo que o modelo consegue capturar parcialmente padrões sequenciais em contextos mais previsíveis, provavelmente por estatisticamente ter mais entidades sequenciais(I-x). No entanto, esses resultados ainda são limitados e insuficientes para compensar a elevada taxa de erros nas demais classes.

**Tabela 2: Resultados do modelo N-gramas + Regressão Logística**

| Classe | Precision | Recall | F1-score |
|---|---|---|---|
| **LOC** | 0.29 | 0.10 | 0.15 |
| **ORG** | 0.25 | 0.09 | 0.13 |
| **PER** | 0.15 | 0.02 | 0.04 |
| **micro avg** | 0.25 | 0.07 | 0.11 |
| **macro avg** | 0.23 | 0.07 | 0.11 |
| **weighted avg** | 0.23 | 0.07 | 0.11 |

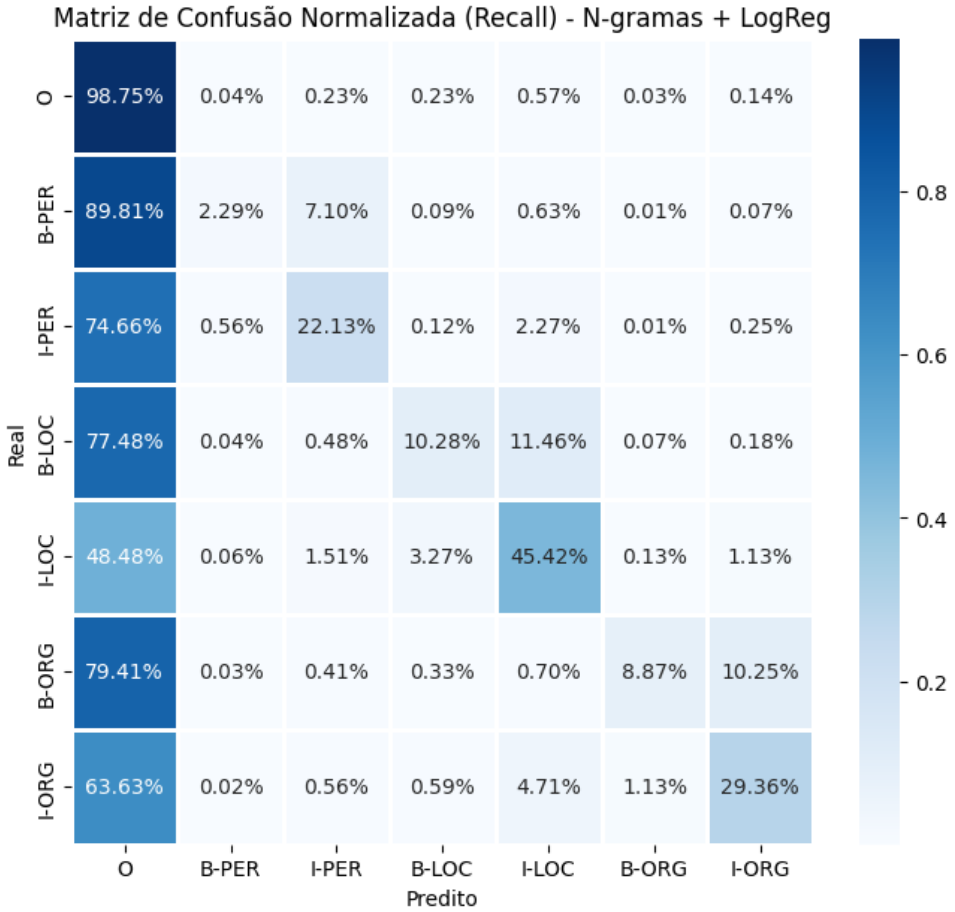


**Figura 2: Matriz de confusão para o N-Gramas**

### 5.3 BERT

O modelo baseado em BERT apresentou uma média de F1-Score de 0.68, evidenciando um desempenho significativamente superior em comparação aos modelos anteriores. Esse resultado indica uma alta capacidade do modelo em identificar e classificar entidades nomeadas de forma consistente, demonstrando sua eficácia na tarefa de Reconhecimento de Entidades Nomeadas em textos da Wikipédia.

A matriz de confusão normalizada do modelo baseado em BERT (Figura 3) evidencia um elevado nível de acerto na diagonal principal, indicando que a maior parte das entidades é corretamente classificada. Destacam-se os resultados para as classes B-PER (82,38%), I-PER (81,25%), B-LOC (79,52%) e I-LOC (77,69%), que apresentam altas taxas de classificação correta, refletindo a capacidade do modelo em capturar dependências contextuais e padrões semânticos complexos.

A classe O apresenta alta taxa de acerto (98,30%), indicando que o modelo é altamente eficiente em identificar corretamente tokens que não pertencem a entidades nomeadas. No entanto, esse comportamento também sugere um viés conservador, no qual o modelo tende, em alguns casos, a classificar entidades como não entidade, impactando levemente a métrica de recall.

**Tabela 3: Resultados do modelo BERTimbau**

| Classe | Precision | Recall | F1-score |
|---|---|---|---|
| **LOC** | 0.73 | 0.74 | 0.73 |
| **ORG** | 0.53 | 0.56 | 0.54 |
| **PER** | 0.77 | 0.77 | 0.77 |
| **micro avg** | 0.72 | 0.73 | 0.72 |
| **macro avg** | 0.67 | 0.69 | 0.68 |
| **weighted avg** | 0.72 | 0.73 | 0.72 |

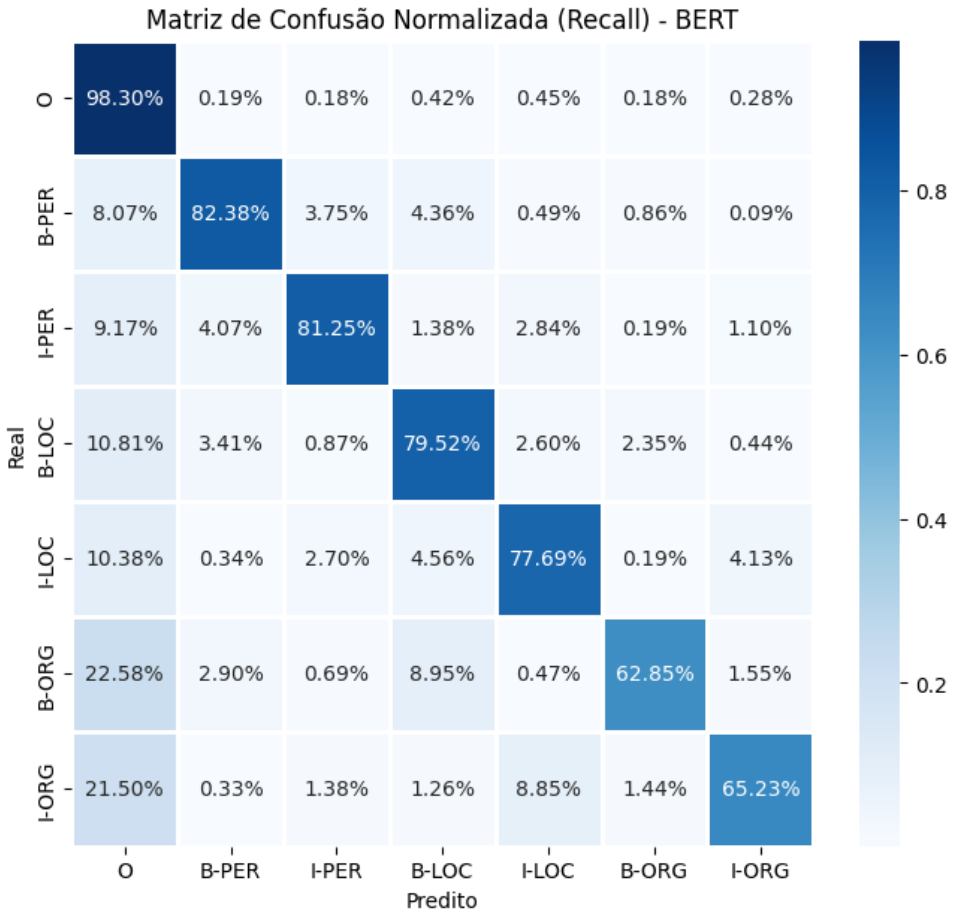


**Figura 3: Matriz de confusão para o BERT**

## 5.4 CONCLUSÃO

A Tabela 4 evidencia uma relação direta entre a complexidade do modelo e seu desempenho na tarefa. O modelo baseado em expressões regulares apresentou desempenho muito inferior, com métricas próximas de zero, demonstrando que abordagens baseadas exclusivamente em regras são insuficientes para lidar com a variabilidade e complexidade dos textos da Wikipédia. Em seguida, o modelo baseado em n-gramas apresentou uma melhora moderada, sendo capaz de capturar padrões locais, porém ainda limitado pela ausência de compreensão contextual, o que impactou negativamente sua capacidade de generalização.

Por outro lado, o modelo baseado em BERT apresentou desempenho significativamente superior, com elevados valores de precision, recall e F1-score em todas as classes analisadas. A análise das matrizes de confusão reforça esse resultado, evidenciando maior concentração de acertos na diagonal principal e melhor capacidade de distinção entre as classes. Ainda assim, foram observadas dificuldades na identificação de entidades do tipo organização, possivelmente em decorrência do desbalanceamento do conjunto de dados e da maior complexidade semântica dessa classe.

**Tabela 4: Tabela comparativa de resultados dos modelos de NER em português**

| Modelo | F1 Macro | Precisão Macro | Revocação Macro | F1 PER | F1 LOC | F1 ORG |
|---|---|---|---|---|---|---|
| **Regex** | 0.0138 | 0.0291 | 0.0249 | 0.0240 | 0.0145 | 0.0030 |
| **N-gramas** | 0.1074 | 0.2281 | 0.0716 | 0.0405 | 0.1513 | 0.1304 |
| **BERT** | 0.6805 | 0.6737 | 0.6875 | 0.7654 | 0.7343 | 0.5416 |

# 6 TRABALHOS FUTUROS

Apesar dos avanços observados na comparação entre as técnicas de NER, este trabalho abre frentes para investigações adicionais. Propõem-se as seguintes extensões para pesquisas futuras:

- **Exploração de Arquiteturas de Deep Learning:** Sugere-se a utilização de bibliotecas como *Flair* e ferramentas como o *DBpedia Spotlight* com o intuito de aprimorar a confiabilidade do *Ground-Truth*, com posteriores avaliações qualitativas.
- **Otimização de Modelos:** Pretende-se investigar modelos mais leves da arquitetura BERT, como o *DistilBERT* e o *BERTimbau Small*. O objetivo é avaliar o *trade-off* entre desempenho preditivo e eficiência computacional, visando aplicações em dispositivos com recursos limitados ou se as métricas de avaliação se mantém nesse cenário.
- **Aprimoramento de Baselines:** No que tange aos métodos tradicionais, planeja-se o refinamento do *Regex* com regras mais robustas de forma a torná-lo mais específico para diferentes classes e a avaliação de diferentes gramas e janelas de contexto para os modelos estatísticos, buscando reduzir o abismo de desempenho entre o tradicional e o neural.
- **Rigor Metodológico e Validação:** Propõe-se a implementação de um *Gold Standard*, ainda que em subconjunto reduzido, com anotação humana especializada para validar os resultados obtidos. Adicionalmente, a aplicação de *Cross-Validation* (Validação Cruzada) garantirá maior robustez estatística aos resultados, mitigando possíveis vieses de divisão do dataset.